



1) Запуск 1. Baseline - параметры, которые были указаны в шаблоне



```
{'output_dir': './output_dir/gpt2-1b-russian',  
'optim': 'adamw_torch_fused',  
'num_train_epochs': 1,  
'per_device_train_batch_size': 4,  
'save_steps': 100,  
'save_total_limit': 2,  
'learning_rate': 5e-05,  
'weight_decay': 0.01,  
'warmup_steps': 200,  
'logging_steps': 1,  
'eval_steps': 100,  
'eval_strategy': 'steps',  
'load_best_model_at_end': True,  
'metric_for_best_model': 'eval_loss',  
'bf16': True,  
'tf32': True,  
'gradient_checkpointing': False,  
'gradient_accumulation_steps': 1,  
'dataloader_num_workers': 4,  
'torch_compile': False, 'report_to': 'none'}
```




Норма градиента быстро снизилась до какого-то предела. Loss убывает, шумный.



По Learning Rate - виден результат линейного warm-up - сначала увеличение достаточно резкое, потом плавное убывание.



По Loss на eval - также убывает, сначала резкий шаг вниз, затем плавное убывание.



Графики Runtime и throughput приводятся для демонстрации стабильности кода и обучения без ошибок/без внезапных неэффективностей.

Eval Loss финальный:

Final evaluation results: {'eval_loss': 7.326803207397461}

Ниже, чем в предыдущем запуске

Примеры генераций:

- Содержат очень много пробелов/переносов строк. Интерпретация: Шаг обучения небольшой, модель обучалась недолго, - хорошо выучила (лучше относительно других токенов) пробелы и

переносы строк, так как они встречаются чаще всего в тексте. На инференсе с большей вероятностью генерирует их

- Также можно увидеть слова присущие оглавлению, названию служебных разделов. Обучались на датасете Википедии, где на каждой странице есть эти служебные слова. Еще раз показывает, что это генерация того, что чаще всего встречалось, и модель выучила на первичном этапе

PROMPT:

Рецепт пирога с яблоками:

GENERATED:

Рецепт пирога с яблоками:

И-пные

– в городе на, что его его, что в которой.

Известные

Примечания

Литература

PROMPT:

У лукоморья дуб зеленый

GENERATED:

У лукоморья дуб зелёный – фильм в «Бёр»¹» (186) – епископ–3, «Коли «Л» – в честь «Тбской» (181838) – в 17 – «Ав» и «У» (1820–1867)

См. также

Литература

PROMPT:
Раз, два, три

GENERATED:
Раз, два, три (186,) —, 18, сын, Николай.

Наостопримечательности

Родка, Россия

См. также

Напобраов, в котором Бий м.

Примечания

Ссылки

Дост

Ссылки

PROMPT:
Столица России — это

GENERATED:
Столица России — это, в этом, и как и к по из его, а на то, а и на этом и в том, как а также.

Сущенский, что на которой и — фильм.

См. также

«Лт» — это из
«Химили, что в результате в отличие».
«Лийные и, в ходе и был на «В ролях, как» — в том же «А», «Гный, что это «Об» в начале, и не было они «В связи с помощью «Ф», а также «Участ2», «

PROMPT:
Вторая буква в русском алфавите — это

GENERATED:
Вторая буква в русском алфавите — это, который в 4-за.

В ролях

2) Запуск 2. Baseline + 'learning_rate': 5e-05 -> 0.0001 - Увеличение LR

Гипотеза: Можем увеличить шаг обучения, модель будет быстрее обучаться, и за такое же время сможет показать лучше качество генерации.

```
{'output_dir': './output_dir/gpt2-1b-russian',
```

```
'optim': 'adamw_torch_fused',
```


```
'num_train_epochs': 1,
```

```
'per_device_train_batch_size': 4,
```

```
'save_steps': 100,
```


```
'save_total_limit': 2,
```


```
'learning_rate': 0.0001,  
'weight_decay': 0.01,  
'warmup_steps': 200,  
'logging_steps': 1,  
'eval_steps': 100,  
'eval_strategy': 'steps',  
'load_best_model_at_end': True,  
'metric_for_best_model': 'eval_loss',  
'bf16': True,  
'tf32': True,  
'gradient_checkpointing': False,  
'gradient_accumulation_steps': 1,  
'dataloader_num_workers': 4,  
'torch_compile': False, 'report_to': 'none'}
```




Поведение Loss на Train и градиентной нормы аналогичное с предыдущим запуском. Не видно, чтобы Loss существенно ниже опустился к концу обучения.

В предыдущем запуске grad norm значение достигало 15, тут немного меньше.





На валидации также плавное убывание.



Eval Loss финальный:

Final evaluation results: {'eval_loss': 7.047975063323975}

Ниже, чем в предыдущем запуске

Примеры генераций:

- По сравнению с предыдущим запуском пробелов и переносов строк стало меньше
- Но всё равно ещё остались артефакты “Литература”, “Примечание”, “Ссылки”
- Как мне показалось, в текстах много местоимений и “служебных” слов типа “Что”, “Кто”, “Такое” и др. Эти слова встречаются чаще других. Можно сказать, Что увеличение шага обучения помогло модели выучить что-то большее, чем переносы строк и пробелы, но при этом все равно ограничивается наиболее часто встречающиеся словами

RESULTS AFTER TRAINING

PROMPT:

Рецепт пирога с яблоками:

GENERATED:

Рецепт пирога с яблоками:

Дожник,
В городе

Д. К. — это этого, как и его, если и не менее, а также в связи с нейге, что позволяет не может быть или менее, но не менее, которые не менее.

Города, что он очень быть в фильме, что не менее в том, например, а также из которых а в фильме.

Потные члены

В городе

По мнению, что менее

За этом детей, которое как и — на основе, и не менее, что менее, и

PROMPT:

У лукоморья дуб зеленый

GENERATED:

У лукоморья дуб зеленый — 2 в «Инда» (Кле) и в зависимости (смеда).

Награды

Примечания

Ссылки

Фильмы-триллеры Великобритании

Библиография

Они-Лавод-Мте-За заслуги в истории-Петербурга

Фильмы-Лавод-За-де-Мте-М-Петербурга-де-Пав-Тя-го-Ф-де-Ж-го-Р-и-и-Петербурга-ПЦ-за-Фильмы-де-Петербурга-Ф-и-

PROMPT:

Столица России — это

GENERATED:

Столица России — это, в семье, не менее, что «Сны, а также и его, и в результате время, но не менее, так как уже, в сфере. По состоянию не менее, что в том, чтобы они также, его не менее как, что, что правило, но его для детей. Он является его не менее, что он всё не

PROMPT:

Вторая буква в русском алфавите — это

GENERATED:

Вторая буква в русском алфавите — это, который в результате правило же, что, что только как не также, однако, что, которые в зависимости с этого, если он можно. В итоге — за несколько, что только и, что его, что в котором он, что он также не менее, а также, что и не

PROMPT:

Раз, два, три

GENERATED:

Раз, два, триним и её, что его их, что он как в связи. Однако, что также была его. Если также в городе, что он и не смог в этом фильме.

В ролях

Библиография и — Б. Д. А. С. В. А. И.

Обзор Аова А. К. История искусство, что «Банк»

«Аосг» К. 1 И. В. П. Библиар»

«И. А. М. «Сумев» в сфере

3) Запуск 3. Baseline + 'learning_rate': 5e-05 -> 0.0001 + Gradient Accumulation Steps 1 -> 4 - Увеличение LR + Увеличение Gradient Accumulation Step

Гипотеза: ожидается более плавное обучение

```
{'output_dir': './output_dir/gpt2-1b-russian',
```

```
'optim': 'adamw_torch_fused',
```

```
'num_train_epochs': 1,
```

```
'per_device_train_batch_size': 4,
```

```
'save_steps': 100,
```

```
'save_total_limit': 2,
```

```
'learning_rate': 0.0001,
```


```
'weight_decay': 0.01,
```

```
'warmup_steps': 200,
```


```
'logging_steps': 1,
```


```
'eval_steps': 100,
```

```
'eval_strategy': 'steps',  
'load_best_model_at_end': True,  
'metric_for_best_model': 'eval_loss',  
'bf16': True,  
'tf32': True,  
'gradient_checkpointing': False,  
'gradient_accumulation_steps': 4,  
'dataloader_num_workers': 4,  
'torch_compile': False, 'report_to': 'none'}
```




Графики Loss и Grad norm стали менее шумными. Аккумуляция градиентов, получается, помогает снизить разброс. По абсолютным значениям к концу обучения - не стало ниже. В предыдущем запуске grad norm значение начиналось с 10 и достигало 14, тут начинается с 6, что показывает более стабильное обучение.





С валидацией все также в порядке - уменьшение Loss.



Eval Loss финальный:

Final evaluation results: {'eval_loss': 6.670175075531006}

Ниже, чем в предыдущем запуске

Примеры генераций:

- Генерации стали разнообразнее. Видны не только “примитивные” слова. Практически устранился эффект пробелов и переносов. А также, служебных слов “Литература”, “Оглавление” и др. также практически нет.
- Аккумуляция градиента помогла стабилизировать обучение. При не аккумуляции градиент могло колебаться из стороны в сторону, что могло приводить в итоге к маленьким абсолютным обновлениям.

RESULTS AFTER TRAINING

PROMPT:
Рецепт пирога с яблоками:

GENERATED:
Рецепт пирога с яблоками:

Улонье

Новая,
,

Гуропёр,
и —

Города

Изёмрия
В некоторых,

Поражология

В

Припел

PROMPT:
У лукоморья дуб зелёный

GENERATED:
У лукоморья дуб зелёный () — фильм в России. В городе А. А. А. Н. Магов, В. В. Тбова. — М., 2001. — С. 1-325.
Зармер. С. А. М. М., И. М. Нова, М., Л. — Т. — 336.
«Погическая энциклопедия». — М., 2002.

Ссылки
Официальный сайт о жизни и языке
Сайт на сайте «Кинокомедия».

Выпуск

PROMPT:
Столица России — это

GENERATED:
Столица России — это, в то время они как в качестве «Су» и то же, и в качестве времени в которой не в том числе.
Существует для времени в которой он за ним, как при этом и в его смерти в его смерти, в конце в которой он все она. Там, но, что в которой является случае в то время как «Дам, но не может быть не бы. Она, как и что и в том числе, не только в том числе, что это время, что

В ролях

Научно

PROMPT:
Вторая буква в русском алфавите — это

GENERATED:
Вторая буква в русском алфавите — это «Ноль и» (М., «Викс», в ходе, «Лве» и «Запро» (1919) — за «Пере» за «У» и «Нарейство» и «Сеп» (1972) и «Стн», «т», и «Боли» (1821)
В городе: «Нол, или «Дис» (1882)» (1872)
«За заслуги» (1898)
«Байон» (1881)
«Сикха» (1829)

PROMPT:
Раз, два, три

GENERATED:
Раз, два, триним, чтобы чего на его и, что он как в случае. В итоге в конце XX года.
Достига — река в течение 2008 года.

Награды

Им — река в период с ним из крупнейших на основе «Средство» (в частности, в отличие от 18 года) и в отличие от «Брат» (3 года — из самых его время — «Парет» (Россия) и «Улоада» (1534), «Мичин» — «Свер» (Сред. — 6

4) Запуск 4. Baseline + 'learning_rate': 5e-05 -> 0.0001 + Gradient Accumulation Steps 1 -> 8 -


Увеличение LR + Увеличение Gradient Accumulation Step

Гипотеза: Еще больше увеличим accumulation step для более стабильного обучения

```
{'output_dir': './output_dir/gpt2-1b-russian',
```



```
'optim': 'adamw_torch_fused',
```

```
'num_train_epochs': 1,  
'per_device_train_batch_size': 4,  
'save_steps': 100,  
'save_total_limit': 2,  
'learning_rate': 0.0001,  
'weight_decay': 0.01,  
'warmup_steps': 200,  
'logging_steps': 1,  
'eval_steps': 100,  
'eval_strategy': 'steps',  
'load_best_model_at_end': True,  
'metric_for_best_model': 'eval_loss',  
'bf16': True,  
'tf32': True,  
'gradient_checkpointing': False,  
'gradient_accumulation_steps': 8,  
'dataloader_num_workers': 4,  
'torch_compile': False, 'report_to': 'none'}
```



Действительно, графики еще более плавные без колебания, как раньше. Здесь можно увидеть, что на графике градиентной нормы появилась отметка “1” по оси Y, которой ранее не было. Если это не издержка в построении графиков, то увеличение аккумуляции градиентов помогло сделать норму градиентов более стабильной (что логично), из за чего она смогла больше уменьшиться. По лоссу - все такая же граница в конце обучения.

В предыдущем запуске grad norm значение начиналось с 6, здесь начинается с 4, что показывает более стабильное обучение.



Eval Loss снижается.

Eval Loss финальный:

Final evaluation results: {'eval_loss': 6.022516250610352}

Ниже, чем в предыдущем запуске

Примеры генераций:

- Также тексты более разнообразные, чем в запусках 1) и 2)
- Нет лишних пробелов, переносов строк
- Встречаются достаточно редкие слова

```

RESULTS AFTER TRAINING

PROMPT:
Рецепт пирога с яблоками:

GENERATED:
Рецепт пирога с яблоками:

Яблоки
- в городе на юге, которое является одним из трехслойных работ (например, в том числе «долги»)

Прочие
В частности, что в рамках «настор» в «Ильин» или «Ильин» - «Эпический» (в книге «Турестон» - «Промет»)

Дост
Библиография
Участие в истории
В честь войны проходили в Лос-Анджелесе, а затем является одним из самых известных книг и не существовало.

Примечания

PROMPT:
У лисуерья дуб зеленый

GENERATED:
У лисуерья дуб зеленый (,, в «Борн» - английская фамилия, в которой является одним из первых стран, который «Пили» в честь Александра П. П. Л. И. (месте с С. А. Поне) - - - - -

PROMPT:
Станица России - это

GENERATED:
Станица России - это по количеству населения, которые также на севере по месту «на берегу внешнего общества» и «Ильин» в большинстве России, а также на кладбище князя в развитии памятника с участием «За боевые заслуги» и «Памятник» (1925) - в честь на Украину, в том числе «Заслуживший похвалы» (19)

Список лучших фильмов
В 2017 году был признан на английский язык «Частный камень»

```

```

PROMPT:
Второе буква в русском алфавите - это

GENERATED:
Второе буква в русском алфавите - это, который в общем случае не раз к тому, что он является в ходе двух до нескольких, а в зависимости от этого до его времени, и в его периода:

В процессе этого времени, что если, если в отличие от центра, которые должны быть бы, а затем, и в этой таблице за счет, но и, что в этом случае они можно найти «выс», он был человеком. Кроме того, как он был вынужден в другом, что его в отличие от того, он - в отличие от имени-Кора в начале того же

В ходе смерти, в этом же время, когда

PROMPT:
Раз, два, три

GENERATED:
Раз, два, три (- в области, например, в настоящего время, в частности, США).

Примечания

Ссылки


Персоналии по алфавиту
Учлене диктаторе Великобритании
Викимедиа СССР
Члены КПСС
Члены ЦК КД Белорусской академии наук
Члены ЦК КД КД АН СССР
Члены парламент Кухи Союза писателей
Члены Совета Союза писателей СССР
Члены Совета Национального общества
Члены Совета Союза Советов СССР (Российские Федерация)
Члены Совета Советов Советов Национальностей от России
Члены ЦК КПСС
Члены Совета Советов Национального общества
Члены КПСС
Действительный

```

5) Запуск 5. (Не до конца отбежал) Baseline + 'learning_rate': 5e-05 -> 0.0003 + Gradient Accumulation Steps 1 -> 8 - Увеличение LR + Увеличение Gradient Accumulation Step

Гипотеза: Еще больше увеличим Learning Rate для более быстрого схождения

```
{'output_dir': './output_dir/gpt2-1b-russian', 'optim': 'adamw_torch_fused', 'num_train_epochs': 1,
'per_device_train_batch_size': 4, 'save_steps': 100, 'save_total_limit': 2, 'learning_rate': 0.0003,
'weight_decay': 0.1, 'warmup_steps': 200, 'logging_steps': 1, 'eval_steps': 100, 'eval_strategy': 'steps',
'load_best_model_at_end': True, 'metric_for_best_model': 'eval_loss', 'bf16': False, 'tf32': True,
'gradient_checkpointing': False, 'gradient_accumulation_steps': 8, 'dataloader_num_workers': 4,
'torch_compile': False, 'report_to': 'none'}
```



Видимо, такой LR уже перебор, т.к. Grad Norm поднимается до 9, в прошлом запуске с меньшим LR так высоко не поднималась. Но нужно больше данных (чтобы запуск добежал до конца).

Итог:

Final Eval Loss уменьшался по мере запусков, значит, проделанные изменения параметров действительно улучшили кач-во генерации и обучения

Далее запланировано было (но не успелось в рамках слота..):

- Попробовать иной оптимизатор
- Уменьшить/увеличить `warmup_steps`,
- Уменьшить/увеличить `'weight_decay'`, чтобы увидеть, как влияет сила регуляризации